

Министерство образования Республики Беларусь
Учреждение образования
«Брестский государственный технический университет»
Кафедра ИИТ

Лабораторная работа №1

По дисциплине: «Обработка изображений в интеллектуальных системах»
Тема: «Обучение классификаторов средствами библиотеки PyTorch»»

Выполнил:
Студент 4 курса
Группы ИИ-25
Трошин И.Д.
Проверила:
Андренко К.В.

Цель работы: научиться конструировать нейросетевые классификаторы и выполнять их обучение на известных выборках компьютерного зрения

Общее задание

1. Выполнить конструирование своей модели СНС, обучить ее на выборке по заданию (использовать **torchvision.datasets**). Предпочтение отдавать как можно более простым архитектурам, базирующимся на базовых типах слоев (сверточный, полносвязный, подвыборочный, слой нелинейного преобразования). Оценить эффективность обучения на тестовой выборке, построить график изменения ошибки (matplotlib);
2. Ознакомьтесь с state-of-the-art результатами для предлагаемых выборок (из материалов в сети Интернет). Сделать выводы о результатах обучения СНС из п. 1;
3. Реализовать визуализацию работы СНС из пункта 1 (выбор и подачу на архитектуру произвольного изображения с выводом результата);
4. Оформить отчет по выполненной работе, загрузить исходный код и отчет в соответствующий репозиторий на github.

Вариант 13

№ варианта	Выборка	Размер исходного изображения	Оптимизатор
13	CIFAR-10	32X32	Adadelata

Архитектура

Сеть состоит из двух блоков: feature extractor (сверточная часть) и classifier (полносвязная часть).

Блок извлечения признаков (features)

Три одинаковых по структуре сверточных блока, каждый Conv2d -> ReLU -> MaxPool2d

Блок	Conv2d	Выход после пулинга
1	3 -> 32 каналов, ядро 3×3, padding=1	32×16×16
2	32 -> 64 канала, ядро 3×3, padding=1	64×8×8
3	64 -> 128 каналов, ядро 3×3, padding=1	128×4×4

Классификатор (classifier)

- Flatten — разворачивает тензор 128×4×4 в вектор из 2048 признаков
- Linear(2048 -> 256) + ReLU
- Dropout(0.5) — регуляризация, случайно зануляет половину активаций во время обучения
- Linear(256 -> 10) — выходной слой, логиты для 10 классов


Результат

Device: cuda
Train images: 50000
Test images: 10000

```
CNN(  
  (features): Sequential(  
    (0): Conv2d(3, 32, kernel_size=(3, 3), stride=(1, 1), padding=(1, 1))  
    (1): ReLU()  
    (2): MaxPool2d(kernel_size=2, stride=2, padding=0, dilation=1, ceil_mode=False)  
    (3): Conv2d(32, 64, kernel_size=(3, 3), stride=(1, 1), padding=(1, 1))  
    (4): ReLU()  
    (5): MaxPool2d(kernel_size=2, stride=2, padding=0, dilation=1, ceil_mode=False)  
    (6): Conv2d(64, 128, kernel_size=(3, 3), stride=(1, 1), padding=(1, 1))  
    (7): ReLU()  
    (8): MaxPool2d(kernel_size=2, stride=2, padding=0, dilation=1, ceil_mode=False)  
  )  
  (classifier): Sequential(  
    (0): Flatten(start_dim=1, end_dim=-1)  
    (1): Linear(in_features=2048, out_features=256, bias=True)  
    (2): ReLU()  
    (3): Dropout(p=0.5, inplace=False)  
    (4): Linear(in_features=256, out_features=10, bias=True)  
  )  
)  
Epoch [1/20] Train Loss: 1.8028 Train Acc: 33.98% Test Loss: 1.4678 Test Acc: 44.93%  
Epoch [2/20] Train Loss: 1.3739 Train Acc: 50.72% Test Loss: 1.0949 Test Acc: 60.20%  
Epoch [3/20] Train Loss: 1.1701 Train Acc: 58.67% Test Loss: 1.0261 Test Acc: 63.27%  
Epoch [4/20] Train Loss: 1.0445 Train Acc: 63.59% Test Loss: 0.9748 Test Acc: 66.11%  
Epoch [5/20] Train Loss: 0.9674 Train Acc: 66.38% Test Loss: 0.8751 Test Acc: 69.77%  
Epoch [6/20] Train Loss: 0.9086 Train Acc: 68.67% Test Loss: 0.7747 Test Acc: 73.25%  
Epoch [7/20] Train Loss: 0.8616 Train Acc: 70.49% Test Loss: 0.8772 Test Acc: 71.22%  
Epoch [8/20] Train Loss: 0.8301 Train Acc: 71.83% Test Loss: 0.7625 Test Acc: 74.07%  
Epoch [9/20] Train Loss: 0.8017 Train Acc: 72.61% Test Loss: 0.7232 Test Acc: 75.78%  
Epoch [10/20] Train Loss: 0.7751 Train Acc: 73.50% Test Loss: 0.7857 Test Acc: 73.45%  
Epoch [11/20] Train Loss: 0.7564 Train Acc: 74.25% Test Loss: 0.6921 Test Acc: 76.81%  
Epoch [12/20] Train Loss: 0.7402 Train Acc: 74.92% Test Loss: 0.6471 Test Acc: 78.79%  
Epoch [13/20] Train Loss: 0.7201 Train Acc: 75.55% Test Loss: 0.7058 Test Acc: 76.46%  
Epoch [14/20] Train Loss: 0.7145 Train Acc: 75.92% Test Loss: 0.6353 Test Acc: 78.83%  
Epoch [15/20] Train Loss: 0.6949 Train Acc: 76.44% Test Loss: 0.6969 Test Acc: 77.76%  
Epoch [16/20] Train Loss: 0.6873 Train Acc: 76.88% Test Loss: 0.6473 Test Acc: 78.97%  
Epoch [17/20] Train Loss: 0.6781 Train Acc: 77.23% Test Loss: 0.6017 Test Acc: 80.11%  
Epoch [18/20] Train Loss: 0.6651 Train Acc: 77.67% Test Loss: 0.6476 Test Acc: 78.48%  
Epoch [19/20] Train Loss: 0.6593 Train Acc: 78.02% Test Loss: 0.6257 Test Acc: 79.27%  
Epoch [20/20] Train Loss: 0.6555 Train Acc: 77.93% Test Loss: 0.7124 Test Acc: 77.43%
```

Best test accuracy: 80.11%

График изменения ошибки



Результаты на тестовой выборке

Pred: cat
Real: cat
84.5%




Pred: ship
Real: ship
97.7%



Pred: ship
Real: ship
48.0%



Pred: ship
Real: airplane
61.4%



Pred: frog
Real: frog
99.4%




Pred: frog
Real: frog
80.4%



Pred: automobile
Real: automobile
60.7%



Pred: frog
Real: frog
28.8%




Pred: cat
Real: cat
98.9%



Pred: automobile
Real: automobile
79.7%



Pred: airplane
Real: airplane
89.0%



Pred: truck
Real: truck
91.4%




Результаты на своих изображениях

Pred: airplane
98.28%



Pred: cat
99.76%



Сравнение со state-of-the-art

Модель	Точность	Подход
ViT-H/14 (JFT-300M)	99.5%	Vision Transformer, предобучен на 300M изображений, дообучен на CIFAR-10
ViT-L/16 (JFT-300M)	99.42%	То же, модель меньше
DeiT-B Distilled	99.10%	Transformer с дистилляцией знаний
ConvNeXt V2 Base	98.7%	Современная CNN-архитектура
ResNet-50 + Cutout	96.01%	Классическая глубокая CNN + аугментация Cutout

SOTA-модели (ViT, DeiT, ConvNeXt V2) превосходят простую CNN преимущественно за счёт предобучения на огромных внешних датасетах (сотни миллионов изображений), что даёт модели готовые визуальные признаки ещё до знакомства с CIFAR-10, а также за счёт более продвинутой архитектуры (механизмы внимания, десятки слоёв с BatchNorm) и продвинутых техник обучения (аугментация Cutout/Mixup, дистилляция знаний, LR-scheduling).

Вывод: в ходе работы была реализована и обучена свёрточная нейронная сеть для классификации изображений CIFAR-10 на 10 классов. Обучение проводилось на 50 000 изображениях с аугментацией (RandomCrop, RandomHorizontalFlip) в течение 17 эпох с использованием оптимизатора Adadelata.